Laboratorio 20

Sesión #20 Introducción a la visualización de datos con Python

Título del Laboratorio: aplicación y uso de la herramienta de Python para hacer el proceso de ETL y visualizaciones.
Duración: 2 horas
Objetivos del Laboratorio:

1. *Afianzar los conocimientos y manejo básico para realizar las visualizaciones de los datos con Python: data, exploración, limpieza y gráficas personalizadas. usando los datos con ejercicios prácticos planteados de acuerdo con el escenario.*

Materiales Necesarios:

1. *Computador con acceso a internet.*
2. *Colocarlo en el repositorio de Github*
3. *Ampliar el conocimiento con el curso de datos en AWS y Cisco.*
4. *Python*

Estructura del Laboratorio:

Parte 1

En la primera parte se aplicarán los temas vistos en la sesión como la Introducción a la visualización de los datos con Python: data, exploración, limpieza y gráficas personalizadas usando los datos, se deberá realizar el paso a paso con las respetivas capturas de pantalla, esta aplicación es de acuerdo con los escenarios planteados.

1. Ejercicio de práctica 1.

Realizar el paso a paso de la visualización de los datos con Python: data, exploración, limpieza y gráficas personalizadas, deberás realizar las respectivas capturas de pantalla, conclusión, guardar el archivo.

1. Escenario 1: Sector Financiero

Una institución bancaria desea analizar la relación entre las características demográficas de sus clientes y su historial crediticio para mejorar la gestión del riesgo de crédito. El banco ha recolectado datos sobre la edad, el género, el historial crediticio, el salario anual y la deuda de sus clientes. Se desea estudiar la relación entre estas variables para identificar patrones de comportamiento y mejorar el proceso de toma de decisiones en la concesión de créditos. Data: datos_financieros.csv

Paso a paso

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

```python
df_financiero = pd.read_csv('./source/datos_financieros.csv')
print(df_financiero)

print(f"""\nResumen de los datos:
{df_financiero.describe()}""")

print(f"""\nVerificación de valores nulos:
{df_financiero.isnull().sum()}""")

df_financiero['Salario_Anual'].fillna(df_financiero['Salario_Anual'].median(), inplace=True)
df_financiero['Deuda'].fillna(df_financiero['Deuda'].median(), inplace=True)

print(f"""\nVerificación de valores nulos después de limpieza
{df_financiero.isnull().sum()}""")

print(f"""\nGuardado de datos limpios
{df_financiero.to_csv('./source/clean/datos_financieros_limpios.csv')}""")
```

```
      Edad Genero Historial_Crediticio  Salario_Anual    Deuda
0       56      M              Regular        61037.0  22443.0
1       69      F                Bueno        31805.0  39725.0
2       46      F                Bueno        63147.0  49212.0
3       32      M                 Malo        94280.0  18595.0
4       60      M              Regular        66053.0   9740.0
...    ...    ...                  ...            ...      ...
4995    24      M              Regular       116777.0  27655.0
4996    66      F                 Malo       101909.0  29143.0
4997    26      F              Regular       107409.0  15698.0
4998    53      F                 Malo        57664.0      NaN
4999    36      F                 Malo        21293.0   9102.0

[5000 rows x 5 columns]

Resumen de los datos:
              Edad  Salario_Anual         Deuda
count  5000.000000    4800.000000   4850.000000
mean     43.584600   69131.827917  25137.928454
std      14.919094   29221.920701  14478.122739
min      18.000000   20005.000000     18.000000
25%      31.000000   43049.500000  12817.500000
50%      43.000000   69636.500000  24841.500000
75%      56.000000   94543.000000  37690.250000
max      69.000000  119987.000000  49999.000000

Verificación de valores nulos:
Edad                    0
Genero                  0
Historial_Crediticio    0
Salario_Anual         200
Deuda                 150
dtype: int64

Verificación de valores nulos después de limpieza
Edad                  0
Genero                0
Historial_Crediticio  0
Salario_Anual         0
Deuda                 0
dtype: int64

Guardado de datos limpios
```

```
plt.figure(figsize=(10, 6))
plt.scatter(df_financiero['Edad'], df_financiero['Deuda'], c='green', alpha=0.5)
plt.title('Relación entre Edad y Deuda', fontsize=15)
plt.xlabel('Edad', fontsize=12)
plt.ylabel('Deuda', fontsize=12)
plt.grid(True)

z = np.polyfit(df_financiero['Edad'], df_financiero['Deuda'], 1)
p = np.poly1d(z)
plt.plot(df_financiero['Edad'], p(df_financiero['Edad']), color='red', label='Tendencia')
plt.legend()

plt.show()

plt.figure(figsize=(8, 6))
df_financiero['Historial_Crediticio'].value_counts().plot(kind='bar', color='skyblue', edgecolor='black'
plt.title('Distribución del Historial Crediticio', fontsize=15)
plt.xlabel('Historial Crediticio', fontsize=12)
plt.ylabel('Cantidad de Clientes', fontsize=12)

plt.grid(axis='y', linestyle='--', alpha=0.7)

plt.show()
```

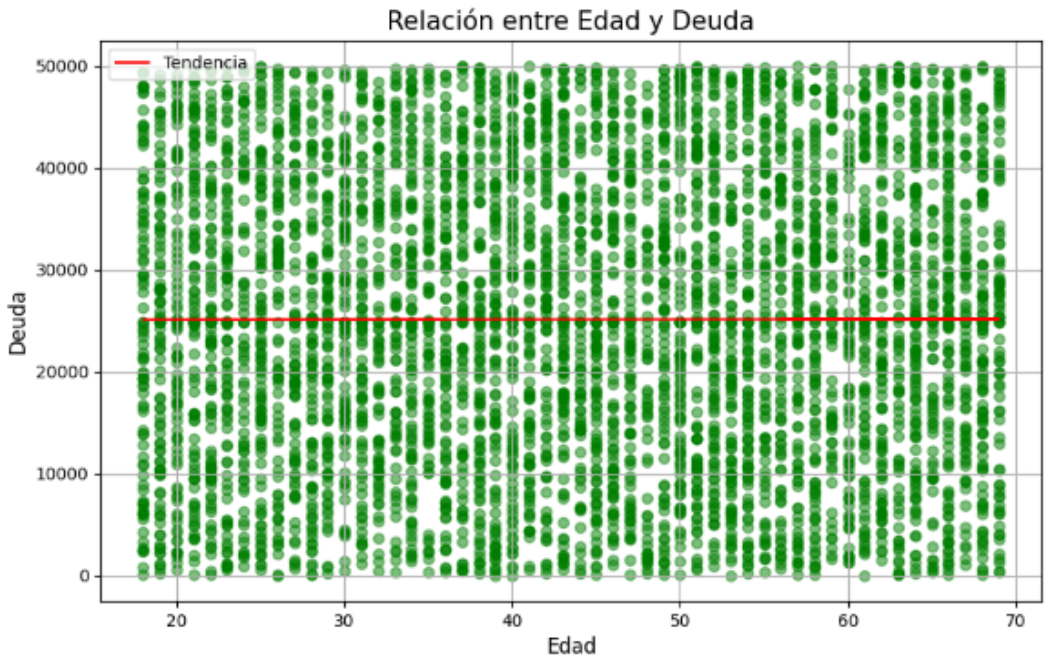

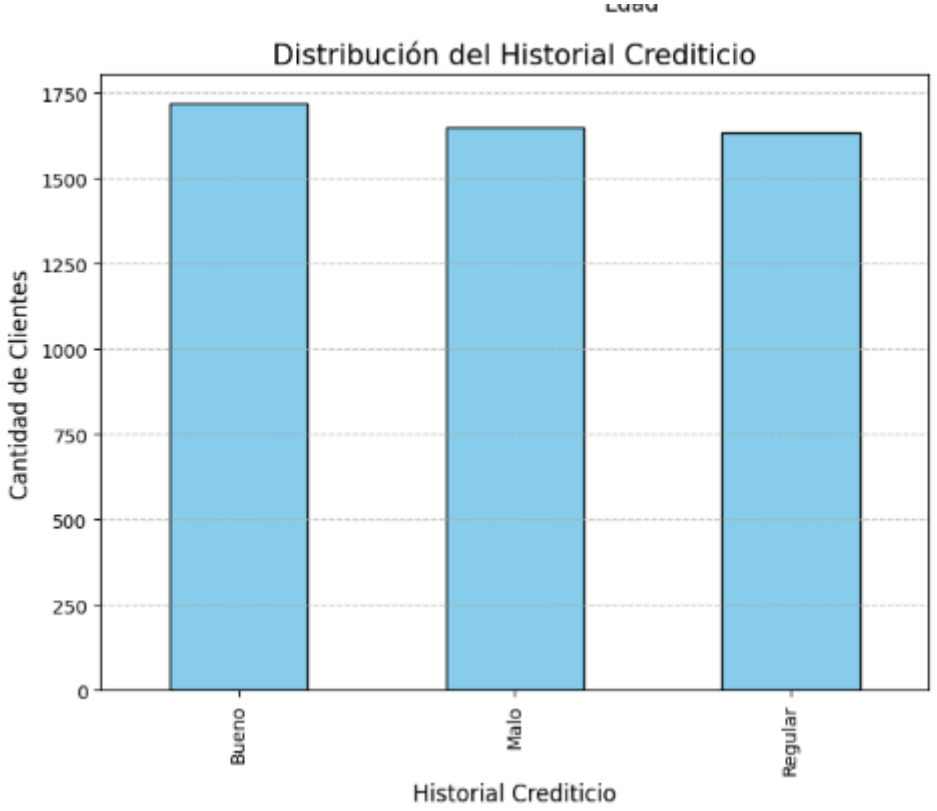
Distribución del Historial Crediticio
Cantidad de Clientes
1750
1500
1250
1000
750
500
250
0
Bueno
Malo
Regular
Historial Crediticio

Conclusión

El análisis de la relación entre las características demográficas de los clientes y su historial crediticio permitirá al banco identificar patrones relevantes para mejorar la gestión del riesgo de crédito. A través de la correlación de variables como edad, género, salario y deuda, se podrán establecer segmentos de clientes y desarrollar modelos predictivos. Esto facilitará decisiones más informadas en la concesión de créditos, reduciendo así la morosidad y optimizando la rentabilidad.

2. **Escenario 2: Sector Salud**

Un hospital está llevando a cabo un estudio para analizar cómo diferentes factores afectan el riesgo de desarrollar diabetes en pacientes. Se han recolectado datos sobre la edad, el género, los niveles de glucosa en sangre, el índice de masa corporal (IMC) y si el paciente tiene antecedentes familiares de diabetes. El objetivo es identificar patrones en los datos para detectar a los pacientes con mayor riesgo de desarrollar esta enfermedad.

Data: datos_salud glu.csv.

Paso a paso

```
[1] df_salud = pd.read_csv('./source/datos_salud glu.csv')
    print(f"""Valores Originales:
    {df_salud.describe()}""")

    print(f"""\nVerificación valores nulos:
    {df_salud.isnull().sum()}""")

    df_salud['Glucosa'].fillna(df_salud['Glucosa'].median(), inplace=True)
    df_salud['IMC'].fillna(df_salud['IMC'].median(), inplace=True)

    print(f"""\nVerificación valores nulos después de limpieza:
    {df_salud.isnull().sum()}""")

    print(f"""\nGuardado de datos limpios:
    {df_salud.to_csv('./source/clean/datos_salud_limpios.csv')}""")
```

```
Valores Originales:
              Edad      Glucosa          IMC
count  5000.000000  4800.000000  4850.000000
mean     53.290000   133.858125    26.708239
std      20.646851    37.196858     4.808900
min      18.000000    70.000000    18.502603
25%      36.000000   101.000000    22.515387
50%      53.000000   134.000000    26.613110
75%      71.000000   165.000000    30.979322
max      89.000000   199.000000    34.998760

Verificación valores nulos:
Edad                      0
Genero                    0
Glucosa                 200
IMC                     150
Antecedentes_Familiares   0
dtype: int64

Verificación valores nulos después de limpieza:
Edad                    0
Genero                  0
Glucosa                 0
IMC                     0
Antecedentes_Familiares 0
dtype: int64

Guardado de datos limpios:
None
<ipython-input-27-981a0346ab86>:8: FutureWarning: A value is trying to be set on a copy of a DataFrame or Series through chained assignment using an inplace method.
The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method({col: value}, inplace=True)' or df[col] = df[col].method(value) instead, to perform the operation inplace on the original object.


  df_salud['Glucosa'].fillna(df_salud['Glucosa'].median(), inplace=True)
<ipython-input-27-981a0346ab86>:9: FutureWarning: A value is trying to be set on a copy of a DataFrame or Series through chained assignment using an inplace method.
The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method({col: value}, inplace=True)' or df[col] = df[col].method(value) instead, to perform the operation inplace on the original object.


  df_salud['IMC'].fillna(df_salud['IMC'].median(), inplace=True)
```

```python
plt.figure(figsize=(10, 6))
plt.scatter(df_salud['Edad'], df_salud['Glucosa'], c='blue', alpha=0.5)
plt.title('Relación entre Edad y Niveles de Glucosa', fontsize=15)
plt.xlabel('Edad', fontsize=12)
plt.ylabel('Niveles de Glucosa', fontsize=12)
plt.grid(True)

z = np.polyfit(df_salud['Edad'], df_salud['Glucosa'], 1)
p = np.poly1d(z)
plt.plot(df_salud['Edad'], p(df_salud['Edad']), color='red', label='Tendencia')
plt.legend()

plt.show()

plt.figure(figsize=(8, 6))
df_salud['Antecedentes_Familiares'].value_counts().plot(kind='bar', color='green', edgecolor='black')
plt.title('Distribución de Antecedentes Familiares de Diabetes', fontsize=15)
plt.xlabel('Antecedentes Familiares', fontsize=12)
plt.ylabel('Cantidad de Pacientes', fontsize=12)

plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```

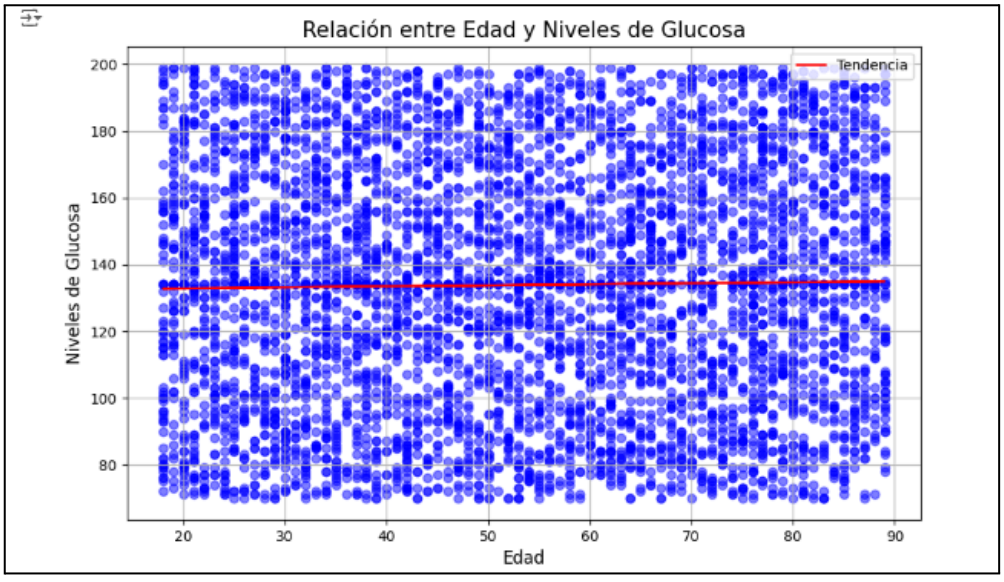

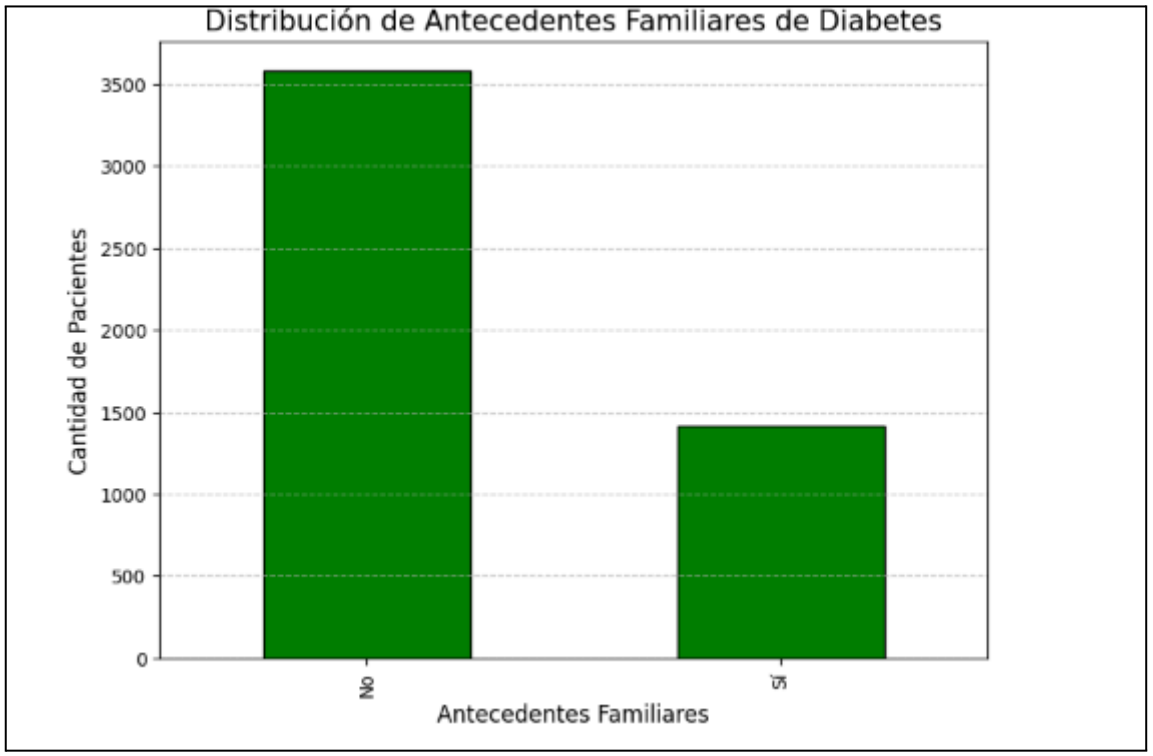

Conclusión

El estudio en el hospital busca analizar cómo factores como la edad, el género, los niveles de glucosa en sangre, el índice de masa corporal (IMC) y los antecedentes familiares de diabetes afectan el riesgo de desarrollar esta enfermedad. Al examinar estos datos, se podrán identificar patrones que ayuden a detectar a los pacientes con mayor probabilidad de desarrollar diabetes. Esto permitirá implementar intervenciones más efectivas y personalizadas para la prevención y el tratamiento, mejorando así la salud de la población atendida.

Parte 2

En la segunda parte una vez realizado el proceso de la visualización de los datos con Python: data, exploración, limpieza y gráficas personalizadas, se deberán guardar los archivos en el repositorio, deberás anexar la captura de pantalla con el nombre del archivo.
Realización de la unidad del curso de AWS o Cisco y anexar captura de pantalla del avance.

2. Ejercicio de práctica 2.
Una vez realizado el proceso de la visualización de los datos con Python: data, exploración, limpieza y gráficas personalizadas se deberán guardar los archivos en el repositorio, deberás anexar la captura de pantalla con el nombre del archivo.
Realización de la unidad del curso de AWS o Cisco y anexar captura del avance del curso.

Imagen del repositorio